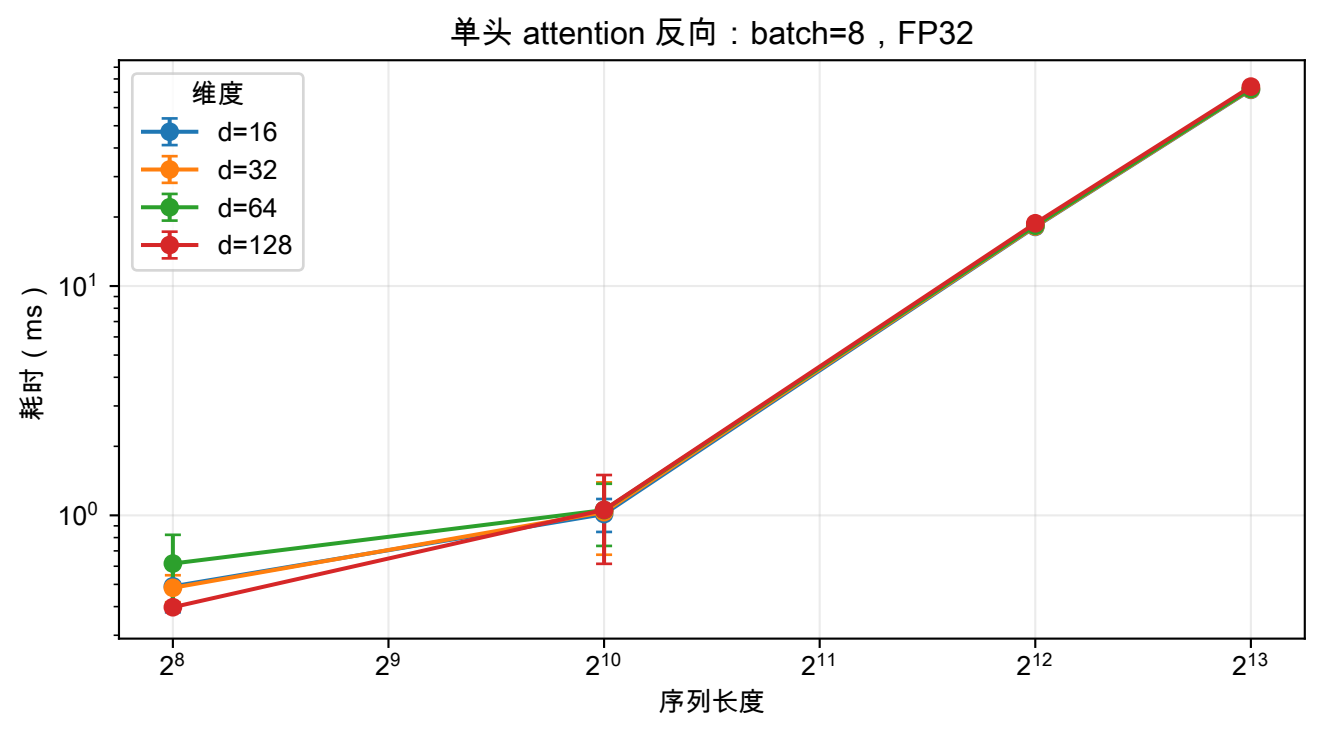
单头 attention 反向：batch=8，FP32
维度
d=16
d=32
d=64
d=128
耗时（ms）
10^1
10^0
2^8
2^9
2^{10}
2^{11}
2^{12}
2^{13}
序列长度