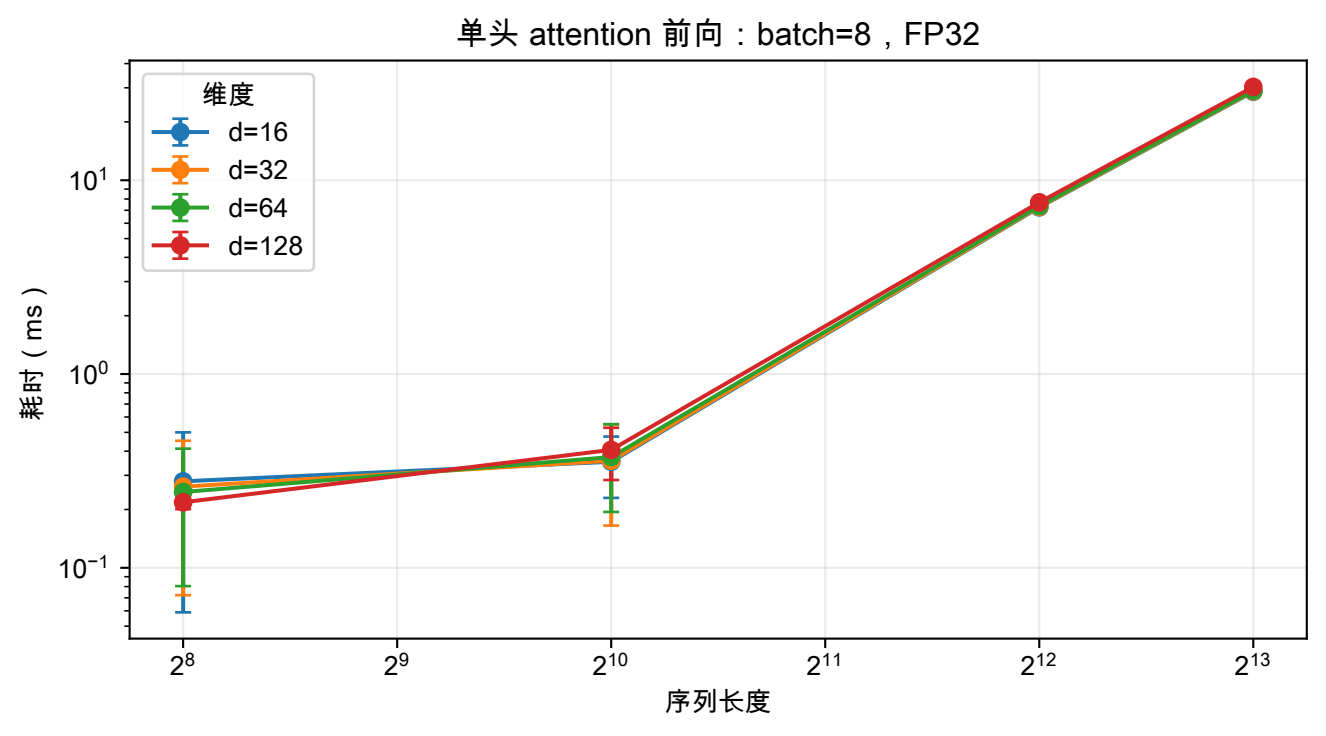
单头 attention 前向：batch=8，FP32
维度
d=16
d=32
d=64
d=128
耗时（ms）
10^{1}
10^{0}
10^{-1}
2^{8}
2^{9}
2^{10}
2^{11}
2^{12}
2^{13}
序列长度