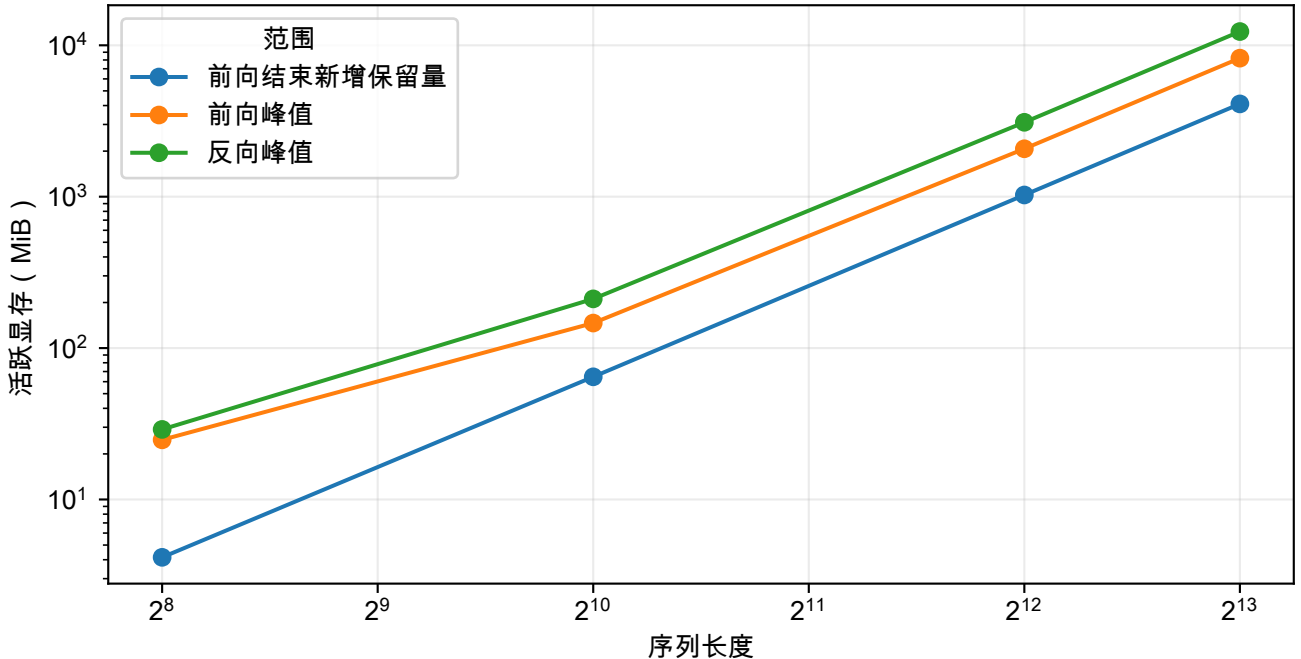
单头 attention 显存：d=16，batch=8，FP32
范围
前向结束新增保留量
前向峰值
反向峰值
活跃显存（MiB）
10^4
10^3
10^2
10^1
2^8
2^9
2^{10}
2^{11}
2^{12}
2^{13}
序列长度