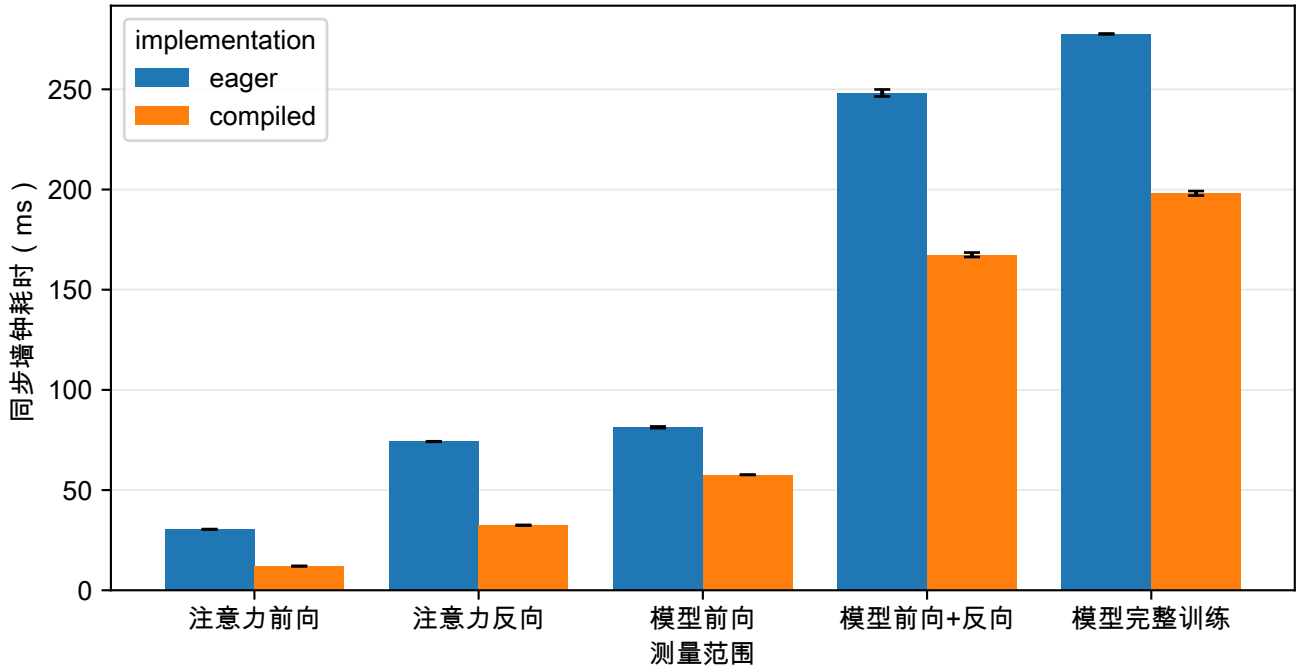
FP32：eager 与 torch.compile
implementation
eager
compiled
同步墙钟耗时（ms）
0
50
100
150
200
250
注意力前向
注意力反向
模型前向
模型前向+反向
模型完整训练
测量范围